

Guide de terrain STATE

Une référence de terrain pour l'ingénieur qui a hérité d'une plateforme d'IA générative, qui s'est retrouvé de garde — et à qui il faut une architecture, pas un meilleur prompt.

S STRUCTURÉ	T TRAÇABLE	A AUDITABLE	T TOLÉRANT	E EXPLICITE
-----------------------	----------------------	-----------------------	----------------------	-----------------------

L'état bat l'intelligence. *Un modèle de milieu de gamme avec une vraie gestion d'état surpasse un modèle frontière qui tourne sans état — chaque fois.*

COMMENT UTILISER CE GUIDE

Vous ne l'avez pas choisi.

Quelqu'un vous a remis une plateforme d'IA générative, l'a déclarée prête pour la production, puis est passé au dossier suivant. Maintenant c'est non déterministe, indébogable, et le risque pose des questions auxquelles vous ne pouvez pas répondre. Ce guide ne vous enseigne pas un meilleur modèle. Il montre les cinq propriétés qui manquent à votre système — et exactement ce qui casse en leur absence.

CHACQUE PAGE DE PILIER SUIT LA MÊME STRUCTURE

- 01 **Définition** — ce que le pilier signifie, en une phrase.
- 02 **Mode de panne** — ce qui arrive en production quand il manque.
- 03 **Question diagnostique** — posez-la à votre système, là, maintenant.
- 04 **Preuve de terrain** — le chiffre ou le principe derrière.

TABLE DES MATIÈRES

03	La thèse et les niveaux de risque	CADRE
04	Pilier S — Structuré	PILIER 1/5
05	Pilier T — Traçable	PILIER 2/5
06	Pilier A — Auditable	PILIER 3/5
07	Pilier T — Tolérant	PILIER 4/5
08	Pilier E — Explicite	PILIER 5/5
09	Le barème et la matrice des écarts	RÉFÉRENCE
10	Carte de référence — schémas et patrons	RÉFÉRENCE
11	La liste S+T+E	RISQUE MOYEN
12	La liste des cinq piliers	RISQUE ÉLEVÉ
13	Taxonomie des pannes en production	RÉF. TERRAIN
14	Quatre pannes qui méritent qu'on s'arrête	NOTES TERRAIN
15	Principes nommés et ce que STATE n'est pas	RÉFÉRENCE

LA THÈSE

L'état bat l'intelligence.

Un modèle de milieu de gamme avec une vraie gestion d'état surpasse un modèle frontière qui tourne sans état — chaque fois. Les systèmes d'IA en production n'échouent pas parce que le modèle est trop faible. Ils échouent parce que personne n'a donné au système une mémoire, un témoin, ni un moyen de dire non.

STATE gouverne chaque opération du pipeline. Le niveau de risque détermine quels piliers sont obligatoires — pas les préférences, pas le budget, pas l'assurance qu'affichait la démo.

Niveaux de risque

NIVEAU	CONDITION	PILIER S REQUIS
Faible	Interne, lecture seule, aucun appel d'API, non personnalisé	S + T
Moyen	Écritures en base de données, appels LLM, API externes, exposition externe	S + T + E
Élevé	Décisions touchant des personnes, opérations financières, données réglementées, portée Loi 25	Les cinq — aucune exception

S+T+E

est le plancher, pas la cible. Chaque commande du pipeline Meta Architect — chaque écriture en base, chaque appel LLM, chaque appel d'API externe — tourne au **risque moyen minimum**. Aucun niveau en dessous ne saute un pilier.

L'habitude diagnostique que ce guide installe : pour chaque pilier, deux questions décident si vous êtes couvert — une question d'état et une question de preuve. Si vous ne pouvez pas répondre aux deux sans ouvrir un journal de conversation ni demander à quelqu'un de « vérifier », le pilier n'existe pas encore. C'est un espoir.

EN PRATIQUE

Deux équipes livrent le même pipeline RAG sur le même modèle. L'équipe A le branche sans objet d'état, sans patron de verrou, sans porte de validation — ça marche en démo, alors ça part en production. L'équipe B enrobe un modèle plus petit et moins cher d'un état explicite, d'une journalisation complète des appels et d'une porte de validation avant chaque écriture. Six semaines plus tard, les deux systèmes affichent le même taux d'erreurs côté modèle — ce n'était jamais ça, le différenciateur. L'équipe A débogue en relisant des fils Slack et en relançant le pipeline à la main, en espérant attraper le bogue en direct. L'équipe B filtre une table de traces par stage et status, et livre le correctif avant le stand-up. Même modèle. Même taux d'échec. Une architecture différente en dessous. C'est la thèse, opérationnalisée — pas une affirmation sur la qualité du modèle, une affirmation sur ce qui l'entoure.

S Structuré

Des schémas d'état explicites, pas du contexte implicite.

Chaque opération initialise un objet d'état typé avant de faire quoi que ce soit. Les entités métier — réclamations, billets, portefeuilles, contenus — sont des objets d'état de plein droit, avec des schémas définis. Le champ **stage** reflète toujours la position d'exécution réelle, pas ce que l'historique de conversation laisse croire.

LE MODE DE PANNE QU'IL PRÉVIENT

La pourriture de contexte. L'agent perd le fil de sa position dans le flux à mesure que la fenêtre de contexte se remplit. L'état ancien est abandonné en silence. Le comportement se dégrade — et rien ne lève d'erreur pour vous dire pourquoi.

QUESTION DIAGNOSTIQUE

« Si cet agent plantait maintenant, pourriez-vous regarder le dernier objet d'état sauvegardé et savoir exactement où le flux s'est arrêté — sans relire l'historique de conversation? »

73,5 %

d'exécution plus rapide, **60 % d'appels LLM en moins** — recherche CA-MCP, en mesurant le passage du contexte implicite à l'état explicite partagé.

APPLICATION TERRAIN

- Le champ **stage** d'un flux est l'unique source de vérité du « où en sommes-nous » — jamais déduit des derniers messages d'une transcription.
- Les entités métier — un billet, une réclamation, un brouillon — sont des lignes avec des schémas, pas du contexte de conversation qui flotte.

« Ce truc est non déterministe. »

COMMENT LES PRATICIENS LE DISENT DÉJÀ



Traçable

Chaque étape observable, chaque décision journalisée.

Journalisez chaque appel LLM, chaque appel d'API externe et chaque transition d'étape significative — avec tous les champs requis, chaque fois. Aucune opération silencieuse. Vous devez pouvoir reconstituer exactement ce que l'agent a fait, ce qu'on lui a donné et ce qu'il a produit — pour n'importe quelle exécution, après coup, sans deviner.

LE MODE DE PANNE QU'IL PRÉVIENT

Le débogage à l'aveugle. « Le modèle a fait quelque chose de bizarre » comme post-mortem. Des pannes qui n'émergent que par leurs effets en aval, trois systèmes plus loin.

QUESTION DIAGNOSTIQUE

« Pouvez-vous afficher, là, maintenant, une trace montrant chaque appel LLM, chaque appel d'outil, chaque entrée et chaque sortie d'une exécution précise de la semaine dernière? »

1 sur 3

équipes d'entreprise se disent satisfaites de leur observabilité et de leur évaluation d'IA — Cleanlab, 2025. Les deux autres déboguent au feeling.

APPLICATION TERRAIN

- Chaque appel LLM obtient une ligne de journal avec version du modèle, résumé de sortie et statut — écrite au moment de l'appel, pas reconstruite de mémoire.
- « Ce que l'agent a vu » et « ce qu'il a fait » sont deux champs différents. Tous deux obligatoires, tous deux requêtables.

« Il n'y a pas de stack trace. »

COMMENT LES PRATICIENS LE DISENT DÉJÀ



Auditable

Prêt pour la gouvernance — explicable sous la Loi 25, l'OSFI et l'EU AI Act.

Pour toute décision automatisée touchant une personne ou utilisant des renseignements personnels, écrivez un enregistrement de décision : quels renseignements personnels ont servi, quels ont été les principaux facteurs, quelle version du modèle et du prompt a tourné, et qui peut la réviser.

LE MODE DE PANNE QU'IL PRÉVIENT

L'exposition réglementaire. L'incapacité de répondre à la question d'un régulateur — ou d'une personne concernée — sur le pourquoi d'une décision automatisée. Pas une lacune technique. Un passif.

QUESTION DIAGNOSTIQUE

« Si un régulateur vous demandait aujourd'hui quelles données votre système a utilisées pour une décision précise le mois dernier – pourriez-vous répondre en moins de 30 minutes? »

25 M\$

ou 4 % du chiffre d'affaires mondial — le maximum pénal de la Loi 25 pour défaut de divulguer une décision automatisée sur demande (10 M\$ / 2 % en sanctions administratives). S'applique largement — pas seulement aux décisions à portée juridique.

Non requis pour l'outillage interne à faible risque sans renseignements personnels. Requis dès que les données d'une vraie personne entrent dans le pipeline.

APPLICATION TERRAIN

- Un enregistrement de décision répond à trois questions avant qu'on ait à les poser : quelles données, quels facteurs, quel modèle.
- « On n'a pas pensé à journaliser ça » n'est pas une réponse défendable à une demande d'accès Loi 25 — une ÉFVP est exigée avant même que l'IA touche aux renseignements personnels.

« Peut-on consigner pourquoi l'agent a fait ça? »

COMMENT LES PRATICIENS LE DISENT DÉJÀ



Tolérant

Tolérant aux pannes, capable de reprendre après l'échec.

Quand le flux échoue à l'étape 6, il reprend à l'étape 6 — pas à l'étape 1. Verrouillez avant les opérations coûteuses. Libérez le verrou à l'échec. Chaque commande peut être retentée. Un run échoué ne laisse aucun état brisé permanent derrière lui.

LE MODE DE PANNE QU'IL PRÉVIENT

Le redémarrage complet après une panne partielle. Le travail perdu. Les systèmes qui ne fonctionnent qu'en marche avant, sur le chemin heureux — et qui tombent la première fois que la réalité ne coopère pas.

QUESTION DIAGNOSTIQUE

« Si ce flux plante à l'étape 6 sur 10, là, maintenant — reprend-il à l'étape 6, ou repart-il de l'étape 1? »

70 %

des entreprises **réglementées** remplacent au moins une partie de leur pile d'IA tous les trois mois — 41 % des non réglementées aussi. Cleanlab, 2025. Voir page 15.

APPLICATION TERRAIN

- L'horodatage de verrou se pose avant le début de l'opération coûteuse, pas après coup — un plantage en cours d'opération devient visible au lieu de silencieux.
- Retenter veut dire reprendre, pas relancer. Un flux qui refait l'étape 1 après avoir échoué à l'étape 6 double le travail et la facture.

« Un prototype rafistolé en production. »

COMMENT LES PRATICIENS LE DISENT DÉJÀ

E

Explicite

Des frontières déterministes, pas de magie.

Chaque sortie de LLM ou d'API externe passe par une porte de validation avant toute écriture ou action. Une sortie invalide est routée vers le chemin d'erreur — jamais de continuation silencieuse. Chaque point où le raisonnement devient action réelle est une porte nommée et validée.

LE MODE DE PANNE QU'IL PRÉVIENT

La cascade d'hallucinations. Le modèle enrobe le JSON dans un bloc markdown, le parseur meurt sans un bruit. Une réponse confiante et fausse déclenche une action en aval, sans aucun contrôle de contrat pour l'arrêter.

QUESTION DIAGNOSTIQUE

« Pour chaque appel LLM de ce flux — quelle est la pire sortie possible, et qu'est-ce qui l'empêche concrètement de devenir une action réelle? »

Coutures vs composants

Tester des nœuds individuels n'est pas tester le flux. Exécutez toujours un passage complet de bout en bout avec de vraies sorties LLM avant de livrer — les données figées prouvent les nœuds, pas les coutures entre eux.

APPLICATION TERRAIN

- Une porte de validation a un nom et un chemin d'échec. « Parser le JSON » n'est pas une porte — « parser le JSON ou router vers error_invalid_output » en est une.
- La pire sortie possible de chaque appel LLM est une donnée de conception, pas un cas limite pour plus tard.

« Je veux juste qu'il dise “je ne sais pas” au lieu d'halluciner. »

COMMENT LES PRATICIENS LE DISENT DÉJÀ

LE BARÈME

Mesurez. Ne devinez pas.

Chaque pilier se note de 0 à 2, selon ses deux questions diagnostiques. Deux oui : 2. Un oui : 1. Deux non, ou « pas sûr » : 0.

SCORE	ÉTIQUETTE
0-3	Risque critique
4-5	Risque élevé
6-7	En développement
8-9	Prêt pour la prod
10	Conforme STATE

Là où les cadres existants s'arrêtent

Outils d'orchestration et d'observabilité, évalués contre les cinq mêmes propriétés de fiabilité.

CADRE	S	T	A	TOL	E
LangGraph					
W&B Weave					
LangSmith					
Arize Phoenix					
OpenTelemetry GenAI					

Fort Partiel Absent

A

est le pilier le moins couvert ici — carrément absent chez quatre sur cinq, et même le crédit partiel d'Arize Phoenix tient au versionnage prompt/modèle et à des annotations manuelles, pas à un artefact natif d'enregistrement de décision. Ce n'est pas un argument marketing pour STATE. C'est un trou dans les outils que vous utilisez déjà.

CARTE DE RÉFÉRENCE

Schémas et patrons

SCHÉMA DE L'OBJET D'ÉTAT

```
{
  workflowId: string,    // crypto.randomUUID() par run
  stage: string,         // nom de l'étape courante
  entityType: string,    // "idea" | "post" | "hook"
  entityId: string,      // id de ligne Supabase (uuid)
  startedAt: string,     // horodatage ISO
  lastUpdatedAt: string // ISO, mis à jour par étape
}
```

SCHÉMA D'ENTRÉE DE JOURNAL

```
{
  workflow_id, entity_id,
  step_name: string,    // p. ex. "research_architect"
  stage: string,        // étape au moment du journal
  timestamp: string,
  output_summary: string,
  model_version: string, // le modèle qui a VRAIMENT
                        // tourné, jamais codé en dur
  status: "success" | "error"
}
```

PATRON DE VERROU

```
// 1. Poser AVANT l'opération
updateRecord(TABLE, id, {
  research_started_at: now()
});

// 2. Libérer à l'échec
updateRecord(TABLE, id, {
  research_started_at: null,
  status: "research_failed"
});
```

CONTRÔLE D'IDEMPOTENCE

```
if (row.research_started_at
    !== null) {
  return "Déjà en cours -
    vérifier avant de retenter.";
}
```

FORMAT D'ERREUR

✗ [Commande] échouée à [étape]

- [message d'erreur]
- verrou libéré, on peut retenter

LISTE – RISQUE MOYEN MINIMUM

La liste S+T+E

Écritures en base, appels LLM, API externes, tout ce qui est exposé à l'externe. C'est le plancher d'un pipeline de contenu, pas le plafond.

- ☐ Objet d'état initialisé avec tous les champs requis
- ☐ Étape mise à jour à chaque transition
- ☐ Chaque appel LLM journalisé dans la table **logs** avec les champs requis
- ☐ Chaque appel d'API externe journalisé dans la table **logs**
- ☐ Verrou posé avant les opérations coûteuses
- ☐ Verrou libéré à l'échec
- ☐ Toute sortie LLM/API validée avant toute écriture en base
- ☐ Le chemin d'erreur rapporte : étape + message d'erreur + verrou confirmé libéré

Une seule case non cochée signifie que le système n'est pas prêt pour la production — peu importe le score du modèle sur un benchmark.

Notez-le ici même

Passez S, T et E par les deux questions diagnostiques de leurs pages (04–08). Deux oui : 2. Un oui : 1. Aucun, ou « pas sûr » : 0. **0–5 sur les trois** veut dire que cette liste est une aspiration, pas une description. Barème complet et niveaux de risque : page 09.

OÙ LES ÉQUIPES ÉCHOUENT D'ABORD SUR CETTE LISTE

- Le verrou est posé mais jamais libéré à l'échec — un run planté à l'air « en cours » pour toujours.
- La sortie LLM est validée pour sa forme, pas son contenu — le JSON parse, mais personne ne l'a confronté au vrai contrat d'écriture.

LISTE – RISQUE ÉLEVÉ / DONNÉES RÉGLEMENTÉES

La liste des cinq piliers

Décisions touchant des personnes. Opérations financières. Données réglementées. Portée Loi 25. Tout ce qui est en page 11, plus :

- ☐ Enregistrement de décision écrit pour toute décision touchant une personne
- ☐ Champs de renseignements personnels énumérés dans l'enregistrement de décision
- ☐ Versions du modèle et du prompt capturées dans l'enregistrement de décision
- ☐ Nœud d'approbation humaine présent pour les décisions à risque élevé
- ☐ Politique de rétention documentée pour les enregistrements de décision

Les cinq

— aucune exception. À ce niveau, un pilier manquant n'est pas un élément de dette technique. C'est la ligne qu'un régulateur trace autour de votre exposition.

AVANT MÊME LA LISTE

La Loi 25 exige une évaluation des facteurs relatifs à la vie privée (ÉFVP) avant que l'IA touche aux renseignements personnels — cette liste est ce que l'ÉFVP vérifie, pas son remplacement. Si personne dans l'équipe ne peut pointer l'ÉFVP, c'est l'élément zéro, au-dessus des cinq.

Référence : page 06 (Auditable) pour le schéma d'enregistrement de décision que cette liste suppose; page 09 pour la note du pilier Auditable chez les outils que vous utilisez peut-être déjà.

LA TAXONOMIE DES PANNES

Dix pannes. Cinq causes racines.

Chacune a déjà été l'objet d'une alerte à 2 h du matin, d'une revue d'incident ou d'un post-mortem « le modèle a fait quelque chose de bizarre ». Aucune n'est un problème de modèle.

MODE DE PANNE	CE QUE VOUS VERREZ	PILIER	LE CORRECTIF
Pourriture de contexte	Le comportement de l'agent dérive au fil d'une longue session; aucune erreur, juste faux.	S	Objet d'état typé par opération; <i>stage</i> reflète toujours la position réelle.
« Le modèle a fait quelque chose de bizarre »	Même entrée, sortie différente; le bogue ne se reproduit pas.	S	Objet d'état journalisé à chaque transition — le post-mortem, c'est l'état, pas le modèle.
Débogage à l'aveugle	Aucune trace d'une exécution précise de la semaine dernière; rien à afficher.	T	Chaque appel LLM/API journalisé avec tous les champs requis, sans exception.
Vol à l'aveugle	Aucune métrique d'hallucination ni de dérive; les problèmes émergent par les plaintes.	T	Reconstitution complète des chaînes de prompts et des appels d'outils, pas seulement des prompts.
Cascade d'hallucinations	JSON enrobé dans un bloc markdown; le parseur meurt en silence, l'action part quand même.	E	Porte de validation nommée avant chaque écriture — l'invalidé route vers l'erreur, jamais plus loin.
Whack-a-mole de prompts	Chaque correctif de prompt en casse un autre; la précision ne tient pas.	E	Coutures vs composants — test complet de bout en bout avec sorties réelles, pas juste le nœud.
L'angle mort réglementaire	« Peut-on consigner pourquoi l'agent a fait ça? » — et la réponse est non.	A	Enregistrement de décision par décision automatisée : données, facteurs principaux, versions modèle/prompt.
Redémarrage complet	Plantage à l'étape 6 sur 10; le flux repart de l'étape 1, le travail est perdu.	To1	Verrou avant les opérations coûteuses, reprise depuis <i>stage</i> , pas depuis zéro.
La reconstruction aux 90 jours	Le système d'agents est rebâti de zéro, encore, sur un cycle prévisible.	To1	Le Test de Redémarrage, réussi avant de prononcer « prêt pour la production ».
Le go/no-go au feeling	Un pilote part en production parce que la démo avait fière allure.	Les 5	Notez-le avec le barème STATE avant la promotion — pas après l'incident.

NOTES DE TERRAIN

Quatre pannes qui méritent qu'on s'arrête.

L'angle mort réglementaire

Le risque et le juridique posent déjà la question : « Peut-on consigner pourquoi l'agent a fait ça? Quelles données a-t-il utilisées? » La Loi 25 ne traite pas ça comme une option — elle exige la divulgation des renseignements personnels utilisés, des principaux facteurs derrière une décision automatisée, et un recours à la révision humaine pour la personne concernée. Manquez-la et l'exposition n'a rien d'hypothétique : jusqu'à 25 M\$ ou 4 % du chiffre d'affaires mondial, au pénal. Posez-vous la question : pourriez-vous répondre à la demande d'un régulateur sur la décision du mois dernier en moins de 30 minutes?

La reconstruction aux 90 jours

La recherche 2025 de Cleanlab montre que 70 % des entreprises réglementées — et 41 % des non réglementées — remplacent au moins une partie de leur pile d'IA tous les trois mois. Pas toujours le système entier, mais assez, assez souvent, pour que la continuité ne tienne jamais. C'est le sort d'un système qui ne survit qu'au chemin heureux : le premier plantage, délai d'attente ou bris de dépendance absent de la démo force une démolition au lieu d'une reprise. Le Test de Redémarrage sert à attraper ça avant le prochain cycle de démolition — redémarrez le service, redémarrez le conteneur, injectez un échec en plein flux, coupez une dépendance deux minutes. Si ça ne fonctionne qu'en marche avant, c'est une démo, pas un système.

Le go/no-go au feeling

Tous les dirigeants de données ressentent la pression de livrer de l'IA générative; presque aucun ne trouve les échéanciers réalistes. Entre ces deux faits se prend une décision go/no-go fondée sur l'allure de la démo, pas sur un score. Le barème STATE existe pour que cette décision porte un chiffre — 0 à 10, cinq piliers, deux questions diagnostiques chacun. Un système qui score 4 et part en production quand même, ce n'est pas un pari. C'est un risque connu que personne n'a écrit.

Cascade d'hallucinations

La panne, ce n'est pas l'hallucination — les modèles auront toujours parfois tort. La panne, c'est la suite : du JSON enrobé dans un bloc markdown, un parseur qui meurt sans un bruit, une réponse confiante et fausse qui déclenche une action en aval parce que rien ne l'a vérifiée d'abord. « Je veux juste qu'il dise "je ne sais pas" au lieu d'halluciner » — c'est la formulation la plus courante chez les praticiens, et c'est un problème de porte de validation, pas un problème de prompt. Pour l'appel LLM de votre flux qui écrit dans quelque chose de réel : qu'est-ce qui empêche, concrètement, la pire sortie de devenir une action réelle?

PRINCIPES NOMMÉS

Trois idées qui méritent un nom.

Le Test de Redémarrage

Avant de déclarer un système prêt pour la production, simulez la transition d'état :

- Redémarrez le service
- Redémarrez le conteneur
- Injectez un échec à une étape intermédiaire
- Mettez une dépendance externe hors ligne deux minutes

Si le système ne fonctionne qu'en marche avant, c'est une démo. S'il survit aux transitions d'état, il approche du réel.

Coutures vs composants

Tester des nœuds individuels, c'est du test de composants. Tester le flux complet avec de vraies sorties LLM traversant chaque frontière, c'est du test d'intégration. Les deux sont requis. Les données figées prouvent que les nœuds fonctionnent. Seul un passage réel prouve que les coutures tiennent aussi.

La question STATE

« Votre agent passe-t-il le test STATE? » S'applique à n'importe quel système d'IA, n'importe quelle pile, n'importe quelle échelle.

Ce que STATE n'est pas

- Pas un cadre d'évaluation de modèles. N'évalue ni la qualité ni la capacité du modèle.
- Pas un cadre MLOps. Ne couvre ni les pipelines d'entraînement ni la gestion des jeux de données.
- Pas un cadre de sécurité. Ne remplace pas la modélisation des menaces.
- Délibérément incomplet. Couvre les cinq propriétés qui manquent le plus souvent aux systèmes d'agents en production.

« Je conçois des systèmes d'IA qui ne lâchent pas. »

— SIMON PARIS, THE META ARCHITECT

The Meta Architect est la pratique de Simon Paris en ingénierie de la fiabilité des IA : des systèmes d'agents de qualité production pour les entreprises à données sensibles qui composent avec la Loi 25, l'OSFI et l'EU AI Act. Pas du prompt engineering. Pas du battage. La plomberie sous les deux.

S

STRUCTURÉ

T

TRAÇABLE

A

AUDITABLE

T

TOLÉRANT

E

EXPLICITE